

◎热点与综述◎

知识图谱与大语言模型协同共生模式及其教育应用综述

李晓理, 刘春芳⁺, 耿劲坤

北京工业大学 信息科学技术学院, 北京 100124

⁺ 通信作者 E-mail: cfliu1985@bjut.edu.cn

摘要:近年, 人工智能技术, 特别是大语言模型、知识图谱技术的迅速发展, 为教育的数字化、智能化转型提供了重要的技术条件。分别分析了大语言模型与知识图谱两技术在智能教育领域的应用优势、现状以及存在的问题。在此基础上, 深入探讨了知识图谱与大语言模型的协同共生模式, 包括两者相互增强的方式方法, 并对协同技术研究现状进行了归纳分析, 总结了近年来在教育领域的相关应用。最后, 对知识图谱与大语言模型技术联合应用于教育领域的发展趋势进行了总结与展望。

关键词:知识图谱(KG); 大语言模型(LLM); 智能教育**文献标志码:**A **中图分类号:**G420; TP399 **doi:**10.3778/j.issn.1002-8331.2410-0481**Survey of Collaborative Symbiosis Mode Between Knowledge Graph and Large Language Model and Its Education Application**LI Xiaoli, LIU Chunfang⁺, GENG Shaokun

College of Information Science and Technology, Beijing University of Technology, Beijing 100124, China

Abstract: In recent years, the rapid development of artificial intelligence technology, especially large language models and knowledge graph technology, has provided important technical conditions for the digital and intelligent transformation of education. Firstly, the application advantages, current status, and disadvantages of large language models and knowledge graphs in the field of intelligent education are analyzed separately. On this basis, the collaborative symbiosis mode between knowledge graph and large language model is discussed in depth, including the ways and means of mutual enhancement between them. Inductive analysis is conducted on the research status of collaborative technology and its relevant applications in the field of education are summarized. Finally, the development trend of the joint application of knowledge graph and large language model in the field of education are summarized and prospected.

Key words: knowledge graph(KG); large language model(LLM); intelligent education

传统教育模式存在许多不足, 如传统教学课堂难以满足不同学生的个性化需求, 学生参与度低和教学资源分配不均、教学效果评估难等。随着大数据、人工智能的不断发展, 传统教育的数字化、智能化将是必然的发展趋势。尤其是近年以大语言模型(large language model, LLM)为代表的人工智能技术迅速发展, 其强大的语言理解与生成能力、上下文学习能力和泛化能力等能够给许多领域(金融、医疗、教育等)提供有效帮助。在教育领域, 个性化学习路径的支持、教学资源的智能推送等都是LLM提高学习效率和教学质量的有效方

式。但是LLM本身还存在许多挑战, 如在实际应用中存在幻觉问题、缺乏可解释性等。而知识图谱(knowledge graph, KG)作为人工智能知识工程领域的前沿代表, 具有结构化的知识存储形式, 且推理的可解释性好, 非常适合于教育领域大量知识点的关联关系建立, 便于学生学习知识点之间的深层关联关系等, 但是图谱构建与补全工作量大、成本高。针对KG与LLM的优缺点, 本文探讨KG与LLM的协同共生模式, 使两者优势互补; 并分析KG与LLM联合应用于教育领域的方式方法, 使其在个性化学习、智能教学资源生成、教学助手、

基金项目:北京市教育科学“十四五”规划2022年度优先关注课题(CDEA22009)。**作者简介:**李晓理(1971—), 男, 博士, 教授, 研究方向为人工智能技术在智能教育中应用等; 刘春芳(1985—), 女, 博士, 副教授, CCF会员, 研究方向为知识图谱、大模型及机器人技术等。**收稿日期:**2024-10-31 **修回日期:**2025-02-21 **文章编号:**1002-8331(2025)15-0001-13

智能评估与反馈等多方面发挥重要作用,有效提升教育质量和效率。

知识图谱与大语言模型协同共生模式及其在教育领域应用的研究和分析包括五部分。首先,介绍知识图谱技术,包括其概念、组织形式、优点及不足,分析知识图谱在教育领域的应用现状;其次,概述大语言模型技术的发展、优点与不足,分析大模型在教育领域的应用现状;然后,探讨并总结KG与LLM的协同共生模式,包括两者相互增强的方式方法以及研究现状等,在此基础上,分析KG与LLM协同、联合应用于教育领域的方式方法、应用现状及模型评估;最后,展望了KG与LLM联合应用于智能教育的前景。

1 知识图谱及其在教育领域的应用

1.1 知识图谱概述

知识图谱(KG)提供了一种符号化形式的知识数据表示方法,通过互连实体及其关系组成网络。网络中节点表示实体,边表示实体之间的连接关系。知识图谱的形式化定义为 $G=(E, R, S)$,其中 E 表示实体名的集合, R 表示实体之间的关系集合, S 表示事实集合^[1]。

知识图谱领域目前存在的大型开放知识库如YAGO^[2]、Freebase^[3]、Wikidata^[4]、OpenKG等,其中OpenKG主要用于促进以中文为核心的知识图谱数据的开放、互联与众包,以及知识图谱工具、模型和平台的开源开放。此外,还有一些特殊的数据集,如MarKG和MARS^[5],专用于测试模型在多模态知识图谱推理上的能力。东南大学的MELBench数据集则涵盖了社交媒体、百科知识和多模态知识图谱,用于多模态实体链接任务。知识图谱应用的优点包括:(1)结构化事实知识,以三元组的形式存储大量事实知识,即(头实体、关系、尾实体),能够提供准确、明确的知识^[6];同时将信息组织成机器可以解释的结构化形式,便于高效查询与推理。(2)利用实体、概念之间的语义关系,能够理解信息的深层含义。(3)具有良好的可扩展性,使其适应不断变化的领域知识。(4)可以利用知识和规则进行智能推理。

知识图谱的构建是将结构化、半结构化或者非结构化的大量数据通过知识抽取、知识融合、知识推理等操作处理后加入知识库。其中(半)结构化数据的知识抽取,可以通过简单的规则和固定的模式实现;而非结构化数据的知识抽取是抽取任务的难点,包括实体识别、关系抽取和事件抽取等^[7-8],如命名实体识别(NER)方法等。但是传统NER模型仍存在许多挑战问题,包括:(1)限于预定义的实体类型;(2)依赖于手动特征;(3)上下文理解能力差等^[9]。

目前,知识图谱库构建中知识抽取以及知识的动态补全一直是知识图谱应用中的难题,尤其是针对非结构化数据,需要耗费人力、物力,时间成本大。

1.2 知识图谱在教育中的应用

目前,关于知识图谱的研究与应用已历经近70年。由于可以组织大量数据,具有高级搜索功能等优点,知识图谱广泛应用于知识检索、知识问答以及金融领域等,并在医疗、教育、机器人等领域受到青睐。本节将重点概述知识图谱在教育领域的应用方式与现状。

在教育领域,知识图谱主要用于建立知识点与知识点之间的关联关系。具体可用于各个学科知识点的构建,并进一步可以跟教学资源(教材、试题、讲义、教学视频等)构建关联。知识图谱非常有利于教学,其针对教师的应用方式包括:

(1)在课前,可辅助老师完成备课与教研工作。由于可以依据老师的教学进度,智能推送备课资源,有效提升了老师的教学效率。

(2)在课后,进行精准的学情分析。利用知识图谱、学习进度与反馈的实时关联,可了解学生的知识掌握情况,帮助老师针对性的制定教学策略。另外,还可以实现课程答疑、知识检索推荐等系列教学功能,有效减轻教师的教学压力。

针对学生的知识图谱应用方式包括:

(1)在课中,帮助学生构建深层次知识体系。将可视化的知识网络图展示给学生,便于学生学习知识点之间的深层关联关系。

(2)在课后,还可以进行个性化学习推荐。通过对学生学习情况的精准检测,为学生量身定制个性化学习方案,并提供具有针对性的优质学习资源^[10-11]。

文献[12]中为课程《科学计算与MATLAB语言》构建了知识图谱,并用于开发整合教学资源与学生个性化学习的教学平台。该平台可实时追踪和记录学生的学习进度和掌握情况,精准定位学生在知识图谱中的位置,根据掌握情况精准推荐下一步的学习内容,动态生成个性化学习路径。文献[13]中为QT和C++课程建立了知识图谱,使两课程合二为一,有效关联课程知识点,实现多模态教学资源的整合和共享,促进学生多视角学习知识,且提高了教学的深度。针对离散数学中学生理解不到位等问题,文献[14]从知识点传授、理解与应用方面提出知识图谱赋能方案。文献[15]中设计了学科知识图谱构建框架,主要分为数据获取、知识抽取、知识融合及知识加工4个环节,并加入质量评估层以动态维护知识图谱的质量。文献[16]综述了课程知识图谱自动构建的各种方法,并提出其中的挑战性问题,如高性能知识点的抽取技术需要大量已标注的训练数据,而手动标注费时费力,多模态课程资源与知识图谱的对齐以及分类等难题。

虽然知识图谱在教育领域有许多潜在应用,但是目前对知识图谱支撑的教育知识服务研究还处于初始阶

段。现有的图谱构建方法仍存在诸多不足,不仅构建效率低、人工成本高,而且多数只考虑单一文本数据,忽略了图像、视频等多模态数据的特征表示等。

2 大模型及其在教育中的应用

2.1 大模型概述

大模型是指具有超大规模参数量的神经网络模型。它从大量文本或多模态数据中进行学习,具有强大的语言理解和生成能力^[17]。狭义的大模型,即大语言模型(LLM),是通过高达万亿词元数量的文本语料训练出来的深度神经网络。广义的大模型则包含了文本、声音、图像等多模态任务,典型代表如 GPT-4、Gemini^[18]、Sora^[19]。

大模型的网络核心主要是利用注意力机制进行序列建模的变换器网络(Transformer)架构,采用预训练和微调两阶段方法对大规模数据集进行训练。在预训练阶段,对大规模语料库进行自监督学习;在微调阶段,模型使用标记的特定任务数据进行训练和调整,使其适应特定任务要求。

早在2018年,OpenAI 发布了 GPT-1 模型,其是基于生成式预训练的 Transformer 架构,采用了无监督预训练和有监督微调相结合的方法,专注于预测下一个词元。而 Google 发布了 BERT 模型,GPT-1 和 BERT 分别代表了自然语言生成和自然语言理解两个领域的早期探索。GPT-2 的参数规模扩大到十亿级别,通过扩大参数规模和使用无监督预训练,提出了一种新的多任务学习框架来提高模型的通用性和灵活性。从2020年始,以 OpenAI 推出的 GPT3 为代表,标志着预训练大模型处于快速发展的阶段。GPT3 的模型参数规模扩展到了千亿级别,提出了“上下文学习”思路,对于需要复杂推理或领域适配的任务显示出良好的解决能力。BERT、T5 等在大规模语料库上预训练的大型语言模型(LLM)能够较好地应对多种自然语言处理任务,比如问答、文本生成等。后续推出大模型包括 InstructGPT^[20]、优化对话能力的 ChatGPT、从文本输入扩展到多模态信息的 GPT-4 以及 GPT-4V^[21]、GPT-4O 等,已具有解决复杂实际任务的能力,比如代码生成和推荐等。

目前,大模型虽然在生成能力、多模态多场景应用能力方面有较大提升。但是仍存在一些问题,包括缺乏事实知识、可解释性差^[22],还会出现幻觉问题,即生成具有错误事实的表述,这些问题也导致大模型在事关重大的场景中应用较难。

2.2 大模型在教育中的应用

由于大模型使用深度学习和大规模数据训练方法来模拟人类语言能力,能够从文本数据中提取有价值的信息。针对目前教育领域存在的个性化学习、教育资源不平等,大模型在教育中的应用方式可包括:

(1)个性化学习。大模型可以根据学生需求和兴趣提供个性化的学习内容和推荐。通过学情分析,大模型可为每个学生设计独特的学习路径,并推荐合适的学习资源,帮助学生高效地学习^[23]。

(2)教师助手。教师可以利用大模型生成的内容和推荐来设计教学活动。也可以根据教学目标和需求生成教学材料、练习等,为教师提供丰富的资源。

(3)教育评估和反馈。大模型可以分析学生的作业等,以评估和反馈他们的学习进度,并自动生成评论和建议,根据此信息,老师可提供相应的指导^[24]。

文献[25]通过教学实践案例阐述了 LLM 在提升资源整合效率、建设双语教学内容等方面的优秀能力。文献[26]阐述了大模型在医疗教育中的应用。文献[27]综述了 LLM 在教育中的应用与特点,能够为学生提供个性化、适应性和针对性的教育支持,提高了学习成果和教学质量,但是也提出了 LLM 应用于教育面临的挑战,如算法透明度(可解释性)、数据偏见等问题。

大模型在教育领域的应用前景虽很好,但同时也存在许多问题。因训练数据的缺失、知识过时、利用不佳等原因,大模型生成的内容会产生幻觉、深度逻辑缺失等现象。“幻觉”现象主要是生成的内容与事实不相符,或是与真实逻辑不一致导致的多步骤错误。而深度逻辑缺失往往是由于专业领域知识不够,使得理解、分析缺乏深度,或推理能力不足导致的数理逻辑推理无法进行。此外,由复杂神经网络训练的教育大模型,其决策过程难以解释和理解,可信度和可接受度仍不足。以上问题若不解决,将直接影响到大模型在教育领域的应用价值。

3 知识图谱与大模型的协同共生模式

从前述总结中可知,知识图谱与大模型各有优缺点,KG 可以提供额外的、结构化的、高质量的知识,其可解释性知识有助于理解模型输出;而 LLM 可以自动从文本数据中提取知识,从而降低 KG 的构建和维护成本等,两者协同工作可以克服各自缺陷,发挥互补优势。本章综述 KG 与 LLM 相互增强的方式与研究现状,并总结了 KG 与 LLM 的协同共生模式。

3.1 知识图谱增强大模型的方式

如图1所示,在知识图谱增强大模型方面,包括3点:

(1)模型预训练。由于大模型在生成文本时依赖语言模型的概率分布,且并不考虑文本与现实世界常识是否一致,因此,会出现幻觉问题。针对该问题,可以利用知识图谱中的结构化信息(实体、关系等),将文本中实体与知识图谱实体对齐,依据实体关系的描述增强大模型的语言表示能力^[28]。文献[29]中提出了一种名为“knowledge graph-based rerofitting (KGR)”的新框架,其主要思想是自主地根据知识图谱中存储的事实知识




图1 知识图谱增强大模型的3种方式

Fig.1 Three ways to enhance large models with knowledge graphs

来效验和改造 LLM 的初始响应,实现基于知识图谱的后验来缓解 LLM 的幻觉问题。

(2)大模型推理。语言模型推理主要依靠神经网络在参数化空间完成,因此是一种隐式推理,虽具有泛化能力,但推理缺乏可解释性;同时,由于推理过程依赖生成过程,若产生幻觉问题,将导致推理结果缺乏可靠性。目前,增强大模型推理能力的主要技术有思维链、思维图等^[30]。然而单独链式思维可能会受到偏见特征影响等^[31],导致推理错误。为克服大模型在结构化推理方面的不足,可将KG的结构化推理及支持可解释的预测能力与大模型结合起来,文献[32]提出KAM-CoT框架,将知识图谱(KG)和思维链(chain-of-thought, CoT)推理相结合,通过在推理过程中引入外部知识,提高大语言模型对复杂问题的推理能力。文献[33]通过检索知识库来增强大模型生成。所提出的 KnowledGPT 模型从多种知识库中获取外部知识,作为对 LLM 生成的补充。

(3)模型可解释性。为更好地理解 and 解释大模型的行为,近期研究人员通过结合知识图和注意力网络等,将大模型推理过程与知识图谱中实体和关系相连接。文献[34]中利用KG增强推理能力和可解释性。神经元与知识关联方法尝试探索模型的内部结构,文献[35]中通过KG抽取来提供模型的深入分析,清晰解释模型的行为。

3.2 大模型增强知识图谱的方式

如图2所示,在大模型增强知识图谱方面,主要体现在4点:

(1)知识图谱构建。知识图谱在捕捉关系方面出色,但构建过程烦琐、困难、人工成本高。利用大模型零样本或少样本学习的信息提取能力^[36],可以直接从非结构化文本中提取实体和关系,无须预定义标签,可大大减少人工成本。例如,利用 ChatGPT 作为信息提取器,指示其提取关键实体、关系和概念。文献[37]提出 iText2KG 的增量式知识图谱构建方法,利用大语言模型从原始文档中构建知识图谱,并通过4个模块(文档提炼器、增量实体提取器、增量关系提取器和图谱集成器)




图2 大模型增强知识图谱的4种方式

Fig.2 Four ways to augment knowledge graphs with large models

实现增量式知识图谱构建,无须事先定义本体或进行监督训练。文献[38]提出一个名为提取-定义-规范化(EDC)的三阶段框架:先利用 LLM 进行开放信息提取,然后定义 schema,最后进行规范化来解决知识图谱构建问题。文献[39]提出一种轻量级和高效的自动化知识图谱构建方法。

(2)知识图谱补全。知识图谱补全(KGC)主要是识别KG中缺失的三元组,通常通过链接预测和实例补全等来实现。利用大模型补全知识图谱的两种方式:一种方式是将大模型作为知识库,用 prompt tuning 的方式从大模型中提取知识;另一种方式是用指令数据结合知识图谱结构信息对大模型进行指令微调^[40-43]。文献[44]提出了一种 MPIKGC 的框架,用于提高知识图谱补全模型的性能。通过查询大语言模型,从多个角度对实体描述、关系理解和结构提取进行补偿,从而扩展基于描述的 KGC 模型的能力。文献[45]提出 GS-KGC 生成式知识图谱补全方法,利用 LLM 通过生成基于子图的问题并从中推导答案来补全知识图谱。表1描述了典型的基于 LLM 增强知识图谱补全的方法。

(3)知识图谱推理。已有的许多知识图谱推理方法利用知识图谱中的图结构信息,如知识图谱嵌入表示学习、基于图神经的知识图谱推理方法等。这些方法基本都是基于监督学习的小模型思路。大模型强大的语义理解能力及自监督学习思路,可以将知识图谱推理方法从文本推理的困难任务中解放出来^[46]。文献[47]中将知识图谱的推理任务,如链接预测、问答等,转化为文本问题,输入大语言模型,由大模型输出对应的预测答案。LARK 利用大模型引导知识图谱的复杂推理,将复杂的知识图谱推理转化为上下文知识图谱搜索和逻辑查询推理两个步骤组合^[48]。文献[49]提出一种高耦合“LLM-VKG”范式,其中KG和LLM协同工作,在图推理的每一步中利用 LLM 检索图结构数据,允许 LLM 动态探索KG中的许多推理路径,并相应地做出决策,具有深度、可靠和灵活高效的推理特点。

(4)知识图谱问答。传统基于知识图谱的问答系统,存在诸多问题,包括需要大量训练数据支撑、构建过

表1 大语言模型应用于知识图谱补全

Table 1 Application of large language model in knowledge graph completion

文献	方法	对知识图谱补全的作用
[40]	提出了一种新的知识图谱补全方法 PKGC	提出更准确评估 KGC 模型性能的框架,并利用预训练语言模型中隐含的知识进行知识图谱补全
[41]	提出一种结构增强的上下文学习和指令微调方法,以及一种知识前缀适配器 KoPA	使 LLM 充分理解知识图谱中的结构信息,并在结构信息的辅助下完成知识图谱的推理
[42]	提出一种大语言模型进行知识图谱补全的新方法	在三元组分类和关系预测方面取得了最先进的性能,在相对较小模型进行微调效果胜过 ChatGPT 和 GPT-4
[43]	提出一种知识图谱补全策略 contextualization distillation	利用 LLM 提取描述性的上下文信息,提高基于预训练语言模型的 KGC 任务性能
[44]	提出一种新的技术框架 MPIKGC	引导 LLM 生成辅助文本,改善 KGC 模型的性能
[45]	提出一种新的生成子图的补全框架 GS-KGC	利用 LLM 生成基于子图的问题并得到答案执行 KGC 任务,有效地平衡了知识图谱的结构和语义

程对专家过度依赖,以及专业系统泛化能力不足等。由 LLM 增强的问答系统通过微调技术或直接应用大模型实现相关操作^[50]。OreoLM 系统中将知识图谱转化为文本形式,并使用预训练的语言模型处理,充分利用 LLM 的理解能力,同时确保知识图谱中信息的正确表示,无须进行复杂的知识图谱编码,就可处理复杂的自然语言问题^[51]。文献[52]提出一种增强思维链的知识改写(chain-of-thought enhanced knowledge rewriting, CoT-KR)方法,通过交替生成推理路径和相应知识,克服单步知识改写的限制,并构建了一种从问答反馈中对齐偏好的训练策略,用于知识图谱问答系统。

3.3 大模型与知识图谱的协同共生关系

从 LLM 与 KG 的技术优缺点及相互增强的方式方法来看,LLM 与 KG 相互补全,协同共生。LLM 能够理解和生成自然语言,具有强大的文本理解和生成能力;KG 则是一种结构化的知识表示形式,提供了事实知识结构化表示,可用于存储和检索实体之间的关系,以及它们的属性和上下文信息。文献[53]阐述到大模型与知识图谱的结合可以实现知识的深度整合与高效利用。知识图谱以网络形式组织知识,建立并可视化知识之间的关联性,而大模型可通过其强大的分析和学习能力对知识图谱里的信息进行深度挖掘与整合,实现对知识的深度理解以及高效提取。

如图3描述了 LLM 与 KG 的协同共生关系。输入多模态结构化、非结构化数据,LLM 与 KG 在知识处理、表示与推理上相互依赖,协同共生。KG 可以利用 LLM 的少样本学习、信息提取、语言理解能力等协助图谱知识的创建及表征。而 KG 通过结构化的专业领域知识增强 LLM 的专业化知识能力,同时,可以减少幻觉现象的产生^[54-55]。

在知识推理方面,KG 与 LLM 都可以基于知识完成不同的推理任务,知识图谱推理的基础和关键之一是对实体和关系语义的准确理解,这正是 LLM 的优势所在,LLM 具有强大的语义理解能力,能够给 KG 中的实体和




图3 KG 与 LLM 的协同共生模式

Fig.3 Collaborative symbiotic model of KG and LLM

关系语义理解带来极大的便利^[56-57]。例如,LLM 特有的基于提示工程的零样本、少样本推理可以应用于知识图谱推理中。另一方面,KG 具备显式知识表示,可以为隐式知识表示的 LLM 提供明确、结构化的知识源,通过 KG 明确的知识引导 LLM 输出,可以探索模型的内部结构,并对模型行为提供直观解释的同时,减少错误表达^[58-60]。因此,KG 与 LLM 若能协同结合,将有效促进模型的推理能力与可解释性。

KnowLM^[61]是一种将 LLM 与 KG 结合的知识抽取大模型,用知识图谱来增强大语言模型的预训练、推理和可解释性,通过整合结构化数据来提升模型的专业水平,同时利用大模型的能力来更新和维护知识图谱。根据不同领域的应用需求,若能够找到 LLM 与 KG 的有效协同融合模式,才能同时发挥 LLM 和 KG 的优势,促进在各领域的落地应用^[62-63]。

4 知识图谱与大模型联合应用于教育领域

在教育领域内,KG 在基本知识、基本技能的学习方面有明显优势,可以辅助学习者形成较高水平的认知结构,比较适合进行知识的表征以及逻辑推理决策。关于 KG 在教育领域的应用,目前研究主要集中在知识图谱本体模型的构建以及多模态教育资源与知识图谱的整

合方面。而 LLM 在丰富学习资源、优化学习过程、提升思维质量等方面具有更高水平,比较适合开展基于自然语言的人机交互^[64]。已有研究主要集中在利用大语言模型进行作文指导、英文翻译、问题解答等方面。

KG 与 LLM 有其各自的特点,且相互融合和补充,两者可在教育应用中相互结合。基于 KG 辅助开展基本知识与技能的教学,而 LLM 的多模态思维链、涌现能力和提示工程等技术,将能够有效扩展 KG 的智能性。利用 LLM 辅助生成优质教学资源,并根据学情不同调整学习方式,可达到更高阶的学习目标。文献[65]中阐述到学生可以通过大模型对知识图谱的解析,明确知识点间的关系,从而构建全面的知识体系;而大模型通过知识图谱可以将学生的学习成果和需求在个体学习路径中进行实时更新,实现个性化教学。以下是 LLM 与 KG 相协同应用于教育的方式以及模型评价指标总结(如图 4 所示)。




图4 KG 与 LLM 的协同应用于教育领域

Fig.4 Collaborative application of KG and LLM in field of education

4.1 KG 与 LLM 协同应用于教育的方式

(1) LLM 增强的 KG 构建:利用知识图谱构建的知识体系,可以建模知识点之间的关联性,形成课程知识脉络,有助于学生对知识点的记忆与深层次理解。但是,由于教学资源多样且分散,难以有效指导专业知识体系的构建,目前,构建方法自动化程度较低、构建成本大,需要对非结构化文本进行处理后生成图谱^[66]。

针对该问题,文献[67]提出一种基于 LLM 的学科知识图谱构建优化流程,利用 ChatGPT 的强大语言理解能力,从多种知识资源中自动化提取知识实体和知识关系来构建学科知识图谱。文献[68]采用百度智能云千帆大模型平台,并结合知识追踪机制,构建了基于大模型

知识追踪的多模态教育知识图谱。文献[69]中,采用 ChatGLM 大语言模型,通过提示词与多轮反馈,引导 LLM 理解试题,使得 LLM 具备挖掘隐藏知识点的能力;并将知识点与知识图谱中实体对齐,最终实现试题与知识图谱实体节点相关联,有效解决了资源无序、利用率低的问题。针对学科知识图谱构建难的问题(海量数据、数据不断更新和动态变化等),文献[70]分析了多模态 LLM 与学科知识图谱两者间的协同、竞争和竞合关系,并提出基于多模态大模型驱动的学科知识图谱构建方法。表 2 总结描述了在教育领域 LLM 增强知识图谱构建的典型应用案例。

(2) LLM 与 KG 协同生成个性化学习路径:利用 LLM 分析学生的学习习惯、兴趣和能力,结合 KG 中的知识结构和逻辑关系,为学生生成个性化的学习路径。知识图谱将课程内容结构化为知识点网络,系统通过实时跟踪学生的学习进度和反馈,动态调整学习路径,确保学生能够在最佳的学习路径上持续进步^[71]。文献[72]提出了一种基于决策树和大模型的学生能力评估,在实验相关知识图谱和决策树泛化模型基础上构建决策合并树,并构造 Prompt,调用 ChatGPT 模型提供的接口,自动生成代理与学习者之间多轮对话,辅助任课教师评估学生对于实验相关的知识或技术的掌握程度,最终实现依据学习者水平推荐学习资料或实验任务的目的,提升个性化实验教学的效率。如图 5 展示了 LLM 与 KG 协同生成个性化学习路径的过程。知识图谱与大模型相互协同作用,完成自动学习资料推荐、学习路径选择、教学资源推荐以及学习进度反馈等工作。

(3) 智能教学资源生成与推荐:利用 LLM 分析学生的学习数据和偏好,将 KG 中的领域知识、结构逻辑与 LLM 的文本生成能力相结合,自动生成符合学生个性化需求的教材、教案、练习题等教学资源,或者为学生推荐符合其兴趣和需求的学习资源^[73]和课程。这些资源可以根据学生的学习进度和能力进行自动调整,满足不同层次学生需求的同时帮助学生发现新的学习领域和兴趣点,激发其学习动力和兴趣。另外,结合 KG 与 LLM,还可以深入分析学生做题中的错误原因,为学生提供针对性的学习建议。方图数据软件公司推出的智能学习系统中,将精选的教材、课程大纲和教师讲义等

表 2 大语言模型增强知识图谱在教育领域的应用

Table 2 Application of large language model enhanced knowledge graph in education field

文献	研究内容	在教育领域的应用
[67]	提出一种基于大语言模型的学科知识体系构建流程	帮助学生建立课程和知识的逻辑关联,用于教育教学方案改革,为教学指导提供依据
[68]	基于大模型知识追踪机制构建了一种多模态教育知识图谱	进行教育知识推理和下游任务,实现个性化教学资源推荐与教学决策
[69]	引入大语言模型,提出一种将课程资源智能链接到知识图谱实体的方法	将课程资源关联到知识图谱,解决了大量资源利用率低的问题,减轻了教师备课负担
[70]	探究多模态大模型和学科知识图谱的关系以及在教育上的应用	有助于教育资源多元聚合以及智能教学产品开发,赋能学科资源个性化推荐,促进人机协同智慧教学




图5 LLM与KG协同生成个性化学习路径

Fig.5 LLM and KG collaborate to generate personalized learning paths

课程资料作为数据源,构建知识图谱。智能系统通过分析学生的行为轨迹和学习数据,能够智能推荐最合适的网络课程、练习题和知识点复习材料,帮助学生强化知识和技能^[74]。学生可以定制自己的学习路径,并通过反馈循环不断优化学习策略。

(4)智能教学辅助:

(a)教案设计:知识图谱可以存储和管理丰富的教学知识点及其关系,大语言模型则可以根据这些知识生成详细的教案。教师可以利用这种协同系统,输入教学主题,快速生成高质量的教学目标、教学内容、教学方法、教学评价等教案相关内容。一方面系统内KG将教学内容进行结构化展示,帮助教师梳理课程知识体系,节省了教师的时间,另一方面,LLM能够实时处理最新的教育资源和信息,在教案设计中引入最新的案例或知识点,保持教案的时效性。例如,在以“环境保护”为主题的跨学科教案设计中,KG可以将地理、生物、化学等学科相关知识点进行关联,LLM则可以根据这些关联生成跨学科的教学活动和综合性的教案^[75]。

(b)习题生成与智能评测:(b1)动态生成习题与试卷。结合KG中的知识点结构,按照难度、题型、正确率等通过LLM动态生成习题与试卷,有效提高题库的多样性与针对性,还可以根据教学进度和学生情况动态调整题库内容,增强教学的灵活性。(b2)智能批改作业与多维度分析。在KG与LLM构建的协同系统中,KG可以识别题目中的关键知识点,然后利用LLM对学生的答案进行语义分析,判断答案的准确性和完整性,实现学生作业和试卷的自动批改。另外,系统可以对学生答案进行多维度评测与分析。系统可识别学生在哪些知识点存在误解,并通过LLM生成针对性的解释和补充材料。多维度分析能够帮助教师更全面地了解学生的学习情况,从而设计更有针对性的教学活动^[76]。

(c)智能问答系统构建^[77]:在LLM的预训练阶段,通过将KG的结构化知识整合到LLM的训练目标中,可以增强其对领域知识的理解,提高问答系统的准确性和可靠性。通过设计多轮对话系统,模拟教师与学生的互

动,问答系统可逐步引导学生思考和解决问题,随时为学生答疑解惑,提高学生学习效率的同时,也减轻教师的工作负担。此外,通过KG与LLM的协同框架,KG可以实时更新知识,确保LLM在回答问题时能够提供最新的信息。例如,谷歌的Minerva模型专门针对数学问题进行优化,使其能够回答微分方程、化学等有难度的学科问题。

文献[78]提出了一种基于教育知识图谱和大语言模型协同的教育资源内容审查方法。利用LLM强大的语义理解能力,并以知识图谱作为知识点及其关联关系的结构化表征,实现对教育资源中特定知识点的快速定位与适用性审查。

在文献[79]中,基于大模型增强的通用人工智能教师架构中提到的增强方法包括精调训练增强场景知识、检索增强认知、多模态融合增强感知,以及用教育知识图谱对大模型输出进行监督等。其中为增强大模型的逻辑推理能力,文中将大模型与外部智能组件进行编排组合来增强其逻辑推理能力。如智能知识引擎 Wolfram Alpha,由庞大的专业知识库组成,可以解决数据、科学技术等1 000多个领域问题。

4.2 模型评估

由以上应用可知,KG与LLM协同将对教育的智能化、数字化产生重要作用。在探索KG与LLM协同应用于教育的方式方法同时,选择合适的模型评价指标等来评估模型的有效性也至关重要。KG与LLM模型的评估指标很多,本节将与教育应用直接相关的模型评估指标以及在检索增强系统、问答系统及其他应用上的评估总结如下:

(1)基于语义相似性的度量指标

语义相似性的度量指标主要包括有BERTScore^[80]、MoverScore^[81]等,可以用于生成答案和参考答案的准确性评估。其中BERTScore^[80]是一种用于衡量文本相似度的指标,通过计算两个句子在BERT模型中embedding编码之间的余弦相似度来评估它们的相似度。该评价指标的优点在于考虑了上下文信息和语义信息,因

此能够更准确地衡量句子之间的相似度,尤其是对语义相似但表达不同的句子,BERTScore也能捕捉到它们之间的相似性,与人类判断的相关性更强。MoverScore^[81]主要是基于上下文向量和距离的文本生成评估指标。文献[72]中关于学生能力的评估就是依据文本相似度原理,使用余弦相似度来计算对话实例和对话范例中文本内容之间的相似性程度,由此获知学习者关于知识或技术掌握程度,向其推荐适合其水平的学习资料或实验任务。

(2) 基于重叠的度量指标

基于词重叠率的方法是指基于词汇的级别计算模型的生成文本和人工的参考文本之间的相似性,经典的指标代表有BLEU、ROUGE和METEOR^[82-83]。

双语评估辅助工具(bilingual evaluation understudy, BLEU)是一种评估机器翻译质量的方法,通过计算机器生成的文本与参考文本之间的重叠来衡量精度,其分数越高,表示机器生成的文本与人类翻译的文本越相似。

$$BLEU = BP \times \exp\left(\sum_{n=1}^N W_n \times \log P_n\right) \quad (1)$$

$$BP = \begin{cases} 1, & lc > lr \\ \exp\left(1 - \frac{lr}{lc}\right), & lc \leq lr \end{cases} \quad (2)$$

式中, lc 表示机器译文的长度, lr 表示最短的参考翻译句子的长度。BLEU需要计算1-gram, 2-gram, ..., N -gram的精确率,一般 N 设置为4。公式中 P_n 指 n -gram的精确率, W_n 指 n -gram的权重, BP 是惩罚因子。BLEU评价指标的优点是易于计算且速度快、应用范围广,其缺点是不考虑语义、句子结构等。

ROUGE(recall-oriented understudy for gisting evaluation)用于评估自动文摘和机器翻译质量的指标,专注于召回率,比较常用有ROUGE-1、ROUGE-2、ROUGE- N 和ROUGE- L 等。其中前两个主要是关注单词个数上有不同,ROUGE-1关注单个单词的匹配,ROUGE-2关注两个连续单词的匹配,计算召回率。ROUGE- N 中“ N ”指的是 N -gram,通过统计 N -gram上的召回率,计算ROUGE- N 分数(见式(3))。ROUGE- L 中的 L 指最长公共子序列(longest common subsequence, LCS),根据LCS的长度计算精确率、召回率和F1分数。ROUGE指标特点是能较好地计算参考序列中单词是否在生成序列出现过,即只关心生成序列的召回率,而不关注准确率。METEOR同时考虑基于整个语料库上的准确率和召回率,获得最终测度。

$$ROUGE-N(x) = \frac{\sum_{S \in \{Reference\ Summaries\}} \sum_{gram_n \in S} Count_{match}(gram_n)}{\sum_{S \in \{Reference\ Summaries\}} \sum_{gram_n \in S} Count(gram_n)} \quad (3)$$

式中,分母是统计在参考译文中 N -gram的个数,而分子

是统计参考译文与机器译文共有的 N -gram个数。其 $Count_{match}$ 的长度是候选输出和一组参考输出中同时出现的 n -gram的最大数量。

(3) RAG系统的评估

RAG(retrieval-augmented generation)通过将信息检索技术与文本生成功能相结合来增强大语言模型的性能。评估RAG检索相关信息、确保流畅性、避免偏见等对提高用户满意度至关重要。文献[63]构建了RAGAS框架用于评估RAG模型的性能,该框架包含有4个评估指标:faithfulness,衡量模型回答的准确性;answer relevance,衡量模型回答与用户查询的相关性;context precision,衡量返回的上下文信息中与查询相关的信息精确度;context recall,衡量返回的上下文信息中覆盖了多大比例的相关信息。

文献[84]对知识图谱增强大模型的GraphRAG进行了综述。为评估GraphRAG系统在信息检索和特定任务生成中的性能,将评估指标分为两类:下游任务评估和检索质量评估。下游任务指标包括F1分数、BERT4Score、GPTScore以及BLEU、ROUGE等等;而检索质量使用答案覆盖率与子图大小的比例、查询相关性、多样性和忠实度评分等指标进行评估。

(4) 问答系统的评估

QAEval(question-answering evaluation)通过自动生成问题和评估答案的方式,来全面评估问答系统生成答案的性能。参考答案由人类专家提供,包含对于给定问题正确的所有可能答案。用于评估答案相关性和信息完整性的常用指标包括精确度、召回率、F1分数及文本相似度度量(如BLEU、ROUGE等)。精确度用于评估系统答案中正确信息的比例;召回率评估系统答案覆盖参考答案中信息的程度。F1分数是精确度和召回率的调和平均。

文献[62]主要采用正确答案数据、准确率、精确率、召回率、F1分数等来评估知识图谱与LLM协同模型的有效性。文献[69]以文本试题为研究对象,通过提示工程设计,分析大语言模型答案的质量,由回答问题的准确率对所提出的模型进行评估验证。文献[74]使用混淆矩阵(真正例、真负例、假正例和假负例)来评估ChatGPT生成反馈的准确性。若使用中学生认为ChatGPT生成的反馈不正确,可以通知教师重新检查生成的反馈。

(5) 其他评估

文献[57]对不同规模的语言模型(如GPT3、Codex、LaMDA、PaLM等)在各种推理任务上进行性能比较,以准确率作为评估指标。文献[70]提到基于专家反馈优化的评估,而针对LLM的幻觉现象,可以创建幻觉检测机制,为输入的内容提供幻觉评估报告。文献[70]对多模态幻觉问题进行分类(可分为图文不符、信息

表3 知识图谱(KG)与大语言模型(LLM)协同评估指标

Table 3 KG and LLM collaborative evaluation indicators

类别	名称	原理
基于语义相似性的度量	BERTScore	计算文本序列之间BERT嵌入向量的余弦相似度
	MoverScore	结合上下文向量和距离度量计算参考文本和生成文本的相似度分数
基于重叠的度量	BLEU	计算生成与参考文本的N-gram重合程度
	ROUGE-N	基于N-gram计算候选与参考文本的重叠
	ROUGE-L	基于最长公共子序列计算候选与参考文本的相似度
	METEOR	结合单元词组精确度、召回率和碎片惩罚计算匹配分数

表4 RAG系统、问答系统等评估

Table 4 Evaluations of RAG system, question answering system and so on

类别	文献	评价指标
RAG系统评估	[63]	faithfulness、answer relevance、context precision和context recall
	[82]	下游任务:F1分数、BERT4Score、GPTScore以及BLEU、ROUGE;检索质量:答案覆盖率与子图大小的比例、查询相关性、多样性和忠实度评分
问答系统评估	[62]	正确答案数量、准确率、精确率、召回率和F1值
	[69]	准确率
其他评估	[57]	准确率
	[70]	专家反馈优化、多模态幻觉检测机制

缺失、语法错误以及语义歧义等),并设置相应的评分标准。

与教育应用直接相关的模型评估指标以及在检索增强系统、问答系统及其他应用上的评估总结,如表3和表4所示。

5 总结与展望

知识图谱与大模型在数据处理方面各有优缺点,KG可以提供结构化的、高质量的知识,具有良好的可解释性;LLM具有强大的语言理解与推理及生成能力。本文在综述KG与LLM相互增强的方式与研究现状基础上,总结了KG与LLM主要在以下几方面的协同共生:(1)LLM增强KG的自动构建与动态补全;(2)KG为LLM提供结构化、专业领域知识,可减少LLM的幻觉问题;(3)LLM与KG在知识推理方面的相互协同可提高图谱推理能力,同时可提高LLM可解释性。

基于以上分析可知,KG与LLM协同在教育领域具有很大的潜能,结合两者特点和发展现状,未来研究应主要包括以下几个方面:(1)专业知识图谱的自动化构建。目前由于教育资源多样且分散,专业知识图谱构建存在工作量大、自动化程度低且成本高的问题。利用LLM将散乱的多模态教育资源整合构建KG是有效减轻KG构建工作量的重要途径。(2)学生个性化学习路径的生成与动态调整。固定的教学方式与资源难以满足不同学习者的个性化需求,而个性化教学中对学生水平的评估以及学习路径动态调整等仍在探索阶段,协同LLM的理解、生成能力与KG的知识逻辑关系表示能力是解决该问题的有效方式。(3)智能教学辅助系统的建立。利用KG与LLM协同的独特优势,开发包括教案设

计、习题生成与智能评测以及智能问答等系统,可以让教师专注于教学设计与指导,灵活改进教学方法,并减轻教师工作负担,因此是未来在教育领域重要的研究方向之一。

总而言之,知识图谱丰富的知识表示能力与大模型强大的信息理解及生成能力相协同应用于教育领域,将在教育资源的智能化和数字化转型中发挥重要作用,有望大大提高学习效率和教学质量。

然而,同时也存在一些挑战性问题。如在数据融合方面,如何将图谱知识有效注入到大语言模型中仍是一个研究难点。有研究者采用知识蒸馏的方法,将图谱知识转化为大语言模型能够理解的文本形式来探索该难题。另外,在隐私保护与安全性方面也存在诸多挑战。由于模型在处理大数据过程中,不可避免会涉及到用户的个人信息,一方面训练数据在传输等过程中将敏感信息泄露或被恶意攻击者利用生成虚假信息等,将会产生严重的后果;另一方面,由于大模型可以推断出用户的身份、习惯等敏感信息,其本身也可能会侵犯到用户的隐私权。在教育应用中,模型还可能会生成不符合人类教育价值取向的内容等。而学生对模型的过度依赖,可能会引发工具滥用,导致作业抄袭、考试舞弊等一系列问题。因此,知识图谱与大模型的协同开发虽具有广阔前景,但是还同时会产生很多问题,需要加以重视,并提出有效的应对措施或制定相关的政策规范。

参考文献:

[1] 黄勃, 吴申奥, 王文广, 等. 图模互补: 知识图谱与大模型融合综述[J]. 武汉大学学报(理学版), 2024, 70(4): 397-412.

HUANG B, WU S A, WANG W G, et al. KG-LLM-MCom:

- a survey on integration of knowledge graph and large language model[J]. Journal of Wuhan University (Natural Science Edition), 2024, 70(4): 397-412.
- [2] SUCHANEK F M, KASNECI G, WEIKUM G. YAGO: a large ontology from wikipedia and WordNet[J]. Journal of Web Semantics, 2008, 6(3): 203-217.
- [3] BOLLACKER K, EVANS C, PARITOSH P, et al. Freebase: a collaboratively created graph database for structuring human knowledge[C]//Proceedings of the 2008 ACM SIGMOD International Conference on Management of Data. New York: ACM, 2008: 1247-1250.
- [4] 王昊奋, 漆桂林, 陈华钧. 知识图谱方法、实践与应用[M]. 北京: 电子工业出版社, 2019: 65-66.
- WANG H F, QI G L, CHEN H J. Knowledge graph: methods, practices, and applications[M]. Beijing: Publishing House of Electronics Industry, 2019: 65-66.
- [5] ZHANG N Y, LI L, CHEN X, et al. Multimodal analogical reasoning over knowledge graphs[C]//Proceedings of the 2022 ACM SIGMOD International Conference on Management of Data. New York: ACM, 2022: 1-20.
- [6] JI S X, PAN S R, CAMBRIA E, et al. A survey on knowledge graphs: representation, acquisition, and applications[J]. IEEE Transactions on Neural Networks and Learning Systems, 2022, 33(2): 494-514.
- [7] 刘登辉. 基于注意力机制的知识图谱嵌入技术研究与应用[D]. 曲阜: 曲阜师范大学, 2023.
- LIU D H. Research and application of knowledge graph embedding technology based on attention mechanism[D]. Qufu: Qufu Normal University, 2023.
- [8] 肖仰华, 徐波, 林欣, 等. 知识图谱概念与技术[M]. 北京: 电子工业出版社, 2020: 160-186.
- XIAO Y H, XU B, LIN X, et al. Knowledge graph: concepts and techniques[M]. Beijing: Publishing House of Electronics Industry, 2020: 160-186.
- [9] ZHONG L F, WU J, LI Q, et al. A comprehensive survey on automatic knowledge graph construction[J]. ACM Computing Surveys, 2023, 56(4): 1-62.
- [10] GUAN H L. An online education course recommendation method based on knowledge graphs and reinforcement learning[J]. Journal of Circuits, Systems and Computers, 2023, 32(6): 1-20.
- [11] 童世伟. 面向在线自适应学习的学习者认知状态建模方法[D]. 合肥: 中国科学技术大学, 2023.
- TONG S W. Cognitive state modeling for the students in online adaptive learning[D]. Hefei: University of Science and Technology of China, 2023.
- [12] 李子亮, 李兴春. 《科学计算与MATLAB语言》课程知识图谱的构建[J]. 智能计算机与应用, 2025, 15(2): 116-123.
- LI Z L, LI X C. Construction of the knowledge graph for the course "Scientific Computing and MATLAB Language"[J]. Intelligent Computer and Applications, 2025, 15(2): 116-123.
- [13] 裴壮, 田秀霞, 李冰雪. 知识图谱赋能的面向对象程序设计C++教学改革与实践[J]. 华东师范大学学报(自然科学版), 2024(5): 104-113.
- PEI Z, TIAN X X, LI B X. Knowledge graph empowered object-oriented programming C++ teaching reform and practice[J]. Journal of East China Normal University (Natural Science), 2024(5): 104-113.
- [14] 杜治娟. 知识图谱赋能的离散数学教学实践[J]. 计算机教育, 2024(6): 114-119.
- DU Z J. Teaching practice of discrete mathematics with knowledge map empowerment[J]. Computer Education, 2024(6): 114-119.
- [15] 和文斌, 董永权, 赵成杰, 等. 基于学科知识图谱的教育知识服务模型构建研究[J]. 数字教育, 2022, 8(6): 21-28.
- HE W B, DONG Y Q, ZHAO C J, et al. Research on the construction of educational knowledge service model based on discipline knowledge graph[J]. Digital Education, 2022, 8(6): 21-28.
- [16] 冯筠, 刘星雨, 栗凯旋, 等. 课程知识图谱自动构建综述[J]. 计算机技术与发展, 2025, 35(1): 1-11.
- FENG J, LIU X Y, LI K X, et al. Survey of automatic construction of course knowledge graph[J]. Computer Technology and Development, 2025, 35(1): 1-11.
- [17] ZHAO W X, ZHOU K, LI J, et al. A survey of large language models[J]. arXiv:2303.18223, 2023.
- [18] TEAM G, ANIL R, BORGEAUD S, et al. Gemini: a family of highly capable multimodal models[J]. arXiv:2312.11805, 2023.
- [19] BROOKS T, PEEBLES B, HOLMES C, et al. Video generation models as world simulators [EB/OL]. (2024-02-15) [2024-10-30]. <https://openai.com/index/video-generation-models-as-world-simulators>.
- [20] OUYANG L, WU J, XU J, et al. Training language models to follow instructions with human feedback[C]//Advances in Neural Information Processing Systems, 2022: 27730-27744.
- [21] CAI S, BAO K, GUO H, et al. GeoGPT4V: towards geometric multi-modal large language models with geometric image generation[J]. arXiv:2406.11503, 2024.
- [22] LIU Y, YAO Y, TON J F, et al. Trustworthy LLMs: a survey and guideline for evaluating large language models' alignment[J]. arXiv:2308.05374, 2023.
- [23] KUO B C, CHANG F T. Y., BAI Z E. Leveraging LLMs for adaptive testing and learning in Taiwan adaptive learning platform(TALP) [C]//Proceedings of the AIED 2023 Workshop on Empowering Education with LLMs—the Next-Gen Interface and Content Generation. Cham: Springer, 2023: 101-110.
- [24] KRUPP L, STEINERT S, KIEFER-EMMANOULIDIS M,

- et al. Challenges and opportunities of moderating usage of large language models in education[C]//Proceedings of the International Conference on Mobile and Ubiquitous Multimedia. New York: ACM, 2024: 249-254.
- [25] 周加贝, 林伟, 霍佳鑫, 等. 智慧引领, 学以致用: 人工智能大模型在四川大学本科教学中的应用探索[J]. 数字与缩微影像, 2024(3): 11-14.
- ZHOU J B, LIN Y, HUO J X, et al. Guided by wisdom, applying what you have learned: the application of artificial intelligence model in undergraduate teaching of Sichuan University[J]. Digital & Micrographic Imaging, 2024(3): 11-14.
- [26] ABD-ALRAZAQ A, ALSAAD R, ALHUWAIL D, et al. Large language models in medical education: opportunities, challenges, and future directions[J]. JMIR Medical Education, 2023, 9: e48291.
- [27] KASNECI E, SESSLER K, KÜCHEMANN S, et al. ChatGPT for good on opportunities and challenges of large language models for education[J]. Learning and Individual Differences, 2023, 103: 102274.
- [28] AGRAWAL G, KUMARAGE T, ALGHAMDI Z, et al. Can knowledge graphs reduce hallucinations in LLMs: a survey [C]//Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Stroudsburg: ACL, 2024: 3947-3960.
- [29] GUAN X Y, LIU Y J, LIN H Y, et al. Mitigating large language model hallucinations via autonomous knowledge graph-based retrofitting[C]//Proceedings of the Thirty-Eighth AAAI Conference on Artificial Intelligence and Thirty-Sixth Conference on Innovative Applications of Artificial Intelligence and Fourteenth Symposium on Educational Advances in Artificial Intelligence. New York: ACM, 2024: 18126-18134.
- [30] BESTA M, BLACH N, KUBICEK A, et al. Graph of thoughts: solving elaborate problems with large language models[C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2024: 17682-17690.
- [31] TURPIN M, MICHAEL J, PEREZ E, et al. Language models don't always say what they think: unfaithful explanations in chain-of-thought prompting[C]//Advances in Neural Information Processing Systems, 2023: 74952-74965.
- [32] MONDAL D, MODI S, PANDA S, et al. KAM-CoT: knowledge augmented multimodal chain-of-thoughts reasoning[C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2024: 18798-18806.
- [33] WANG X, YANG Q, QIU Y, et al. KnowledGPT: enhancing large language models with retrieval and storage access on knowledge bases[J]. arXiv:2308.11761. 2023.
- [34] CHEN Z C, CHEN J D, SINGH A, et al. XplainLLM: a knowledge-augmented dataset for reliable grounded explanations in LLMs[C]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL, 2024: 7578-7596.
- [35] DAI D M, DONG L, HAO Y R, et al. Knowledge neurons in pretrained transformers[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics. Stroudsburg: ACL, 2022: 8493-8502.
- [36] WADHWA S, HASSANZADEH O, BHATTACHARJYA D, et al. Distilling event sequence knowledge from large language models[C]//Proceedings of the International Semantic Web Conference. Cham: Springer, 2025: 237-255.
- [37] LAIRGI Y, MONCLA L, CAZABET R, et al. iText2KG: incremental knowledge graphs construction using large language models[C]//Proceedings of the International Conference on Web Information Systems Engineering. Singapore: Springer, 2025: 214-229.
- [38] ZHANG B W, SOH H. Extract, define, canonicalize: an LLM-based framework for knowledge graph construction[C]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL, 2024: 9820-9836.
- [39] CHEN B H, BERTOZZI A L. AutoKG: efficient automated knowledge graph generation for language models[C]//Proceedings of the 2023 IEEE International Conference on Big Data. Piscataway: IEEE, 2023: 3117-3126.
- [40] LV X, LIN Y K, CAO Y X, et al. Do pre-trained models benefit knowledge graph completion a reliable evaluation and a reasonable approach[C]//Findings of the Association for Computational Linguistics(ACL 2022). Stroudsburg: ACL, 2022: 3570-3581.
- [41] ZHANG Y C, CHEN Z, GUO L B, et al. Making large language models perform better in knowledge graph completion [C]//Proceedings of the 32nd ACM International Conference on Multimedia. New York: ACM, 2024: 233-242.
- [42] YAO L, PENG J Z, MAO C S, et al. Exploring large language models for knowledge graph completion[C]//Proceedings of the 2025 IEEE International Conference on Acoustics, Speech and Signal Processing. Piscataway: IEEE, 2025: 1-5.
- [43] LI D, TAN Z, CHEN T, et al. Contextualization distillation from large language model for knowledge graph completion [C]//Findings of the Association for Computational Linguistics(EACL 2024). Stroudsburg, PA: Association for Computational Linguistics, 2024: 9820-9836.
- [44] XU D, ZHANG Z, LIN Z, et al. Multi-perspective improvement of knowledge graph completion with large language models[C]//Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024). Paris: ELRA and ICCL, 2024: 11956-11968.
- [45] YANG R, ZHU J, MAN J, et al. Exploiting large language models capabilities for question answer-driven knowledge

- graph completion across static and temporal domains[J]. arXiv: 2408.10819, 2024.
- [46] HUANG Y. Evaluating and enhancing large language models for conversational reasoning on knowledge graphs[J]. arXiv: 2312.11282, 2023.
- [47] JUNG J, QIN L H, WELLECK S, et al. Maieutic prompting: logically consistent reasoning with recursive explanations [C]//Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL, 2022: 1266-1279.
- [48] CHOUDHARY N, REDDY C K. Complex logical reasoning over knowledge graphs using large language models[J]. arXiv: 2305.01157, 2023.
- [49] SUN J, XU C, TANG L, et al. Think-on-graph: deep and responsible reasoning of large language model on knowledge graph[C]//Proceedings of the 12th International Conference on Learning Representations(ICLR 2024). New York: Curran Associates, Inc, 2024.
- [50] TAFFA T A, USBECK R. Leveraging LLMs in scholarly knowledge graph question answering[C]//Joint Proceedings of Scholarly QALD 2023 and SemREC 2023 co-located with 22nd International Semantic Web Conference. Cham: Springer Nature Switzerland, 2023.
- [51] HU Z N, XU Y C, YU W H, et al. Empowering language models with knowledge graph reasoning for open-domain question answering[C]//Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL, 2022: 9562-9581.
- [52] WU Y K, HUANG Y, HU N, et al. CoTKR: chain-of-thought enhanced knowledge rewriting for complex knowledge graph question answering[C]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL, 2024: 3501-3520.
- [53] PAN S R, LUO L H, WANG Y F, et al. Unifying large language models and knowledge graphs: a roadmap[J]. IEEE Transactions on Knowledge and Data Engineering, 2024, 36(7): 3580-3599.
- [54] 王鑫, 陈子睿, 王昊奋. 知识图谱与大语言模型协同模式探究[J]. 中国计算机学会通讯, 2023, 19(11): 10-16.
WANG X, CHEN Z R, WANG H F. Exploring synergy between KGs and LLMs[J]. Communications of the CCF, 2023, 19(11): 10-16.
- [55] 陈佼, 甄化春. 大模型时代下知识图谱应用的新范式[J]. 中国计算机学会通讯, 2023, 19(11): 38-45.
CHEN J, ZHEN H C. A new paradigm for the application of knowledge graphs in the era of LLMs[J]. Communications of the CCF, 2023, 19(11): 38-45.
- [56] KOJIMA T, GU S S, REID M, et al. Large language models are zero-shot reasoners[C]//Advances in Neural Information Processing Systems, 2022: 22199-22213.
- [57] QIAO S F, OU Y X, ZHANG N Y, et al. Reasoning with language model prompting: a survey[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics. Stroudsburg: ACL, 2023: 5368-5393.
- [58] HU L M, LIU Z Y, ZHAO Z W, et al. A survey of knowledge enhanced pre-trained language models[J]. IEEE Transactions on Knowledge and Data Engineering, 2024, 36(4): 1413-1430.
- [59] 陈华钧, 张宁豫, 张文, 等. 大模型增强的语言与知识推理[J]. 中国计算机学会通讯, 2023, 19(11): 17-25.
CHEN H J, ZHANG N Y, ZHANG W, et al. Augmented language reasoning and knowledge reasoning with large models[J]. Communications of the CCF, 2023, 19(11): 17-25.
- [60] ZHU Y Q, WANG X H, CHEN J, et al. LLMs for knowledge graph construction and reasoning: recent capabilities and future opportunities[J]. World Wide Web, 2024, 27(5): 58.
- [61] ZHANG N, ZHANG J, WANG X, et al. KnowLM technical report[EB/OL]. [2024-12-25]. <http://knowlm.zjukg.cn/>.
- [62] LIU P F, QIAN L, ZHAO X W, et al. Joint knowledge graph and large language model for fault diagnosis and its application in aviation assembly[J]. IEEE Transactions on Industrial Informatics, 2024, 20(6): 8160-8169.
- [63] KULKARNI P S, JAIN M, SHESHANARAYANA D, et al. HeCiX: integrating knowledge graphs and large language models for biomedical research[J]. arXiv:2407.14030, 2024.
- [64] GAN W S, QI Z L, WU J Y, et al. Large language models in education: vision and opportunities[C]//Proceedings of the 2023 IEEE International Conference on Big Data. Piscataway: IEEE, 2023: 4776-4785.
- [65] XU T, MA X, WANG F, et al. Construction and application of subject knowledge graph for basic education[C]//Proceedings of the International Conference on Computer and Information Processing Technology, 2022: 58-63.
- [66] AGRAWAL M, HEGSELMANN S, LANG H, et al. Large language models are few-shot clinical information extractors[C]//Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL, 2022: 1998-2022.
- [67] 唐晓晟, 程琳雅, 张春红, 等. 大语言模型在学科知识图谱自动化构建上的应用[J]. 北京邮电大学学报(社会科学版), 2024, 26(1): 125-136.
TANG X S, CHENG L Y, ZHANG C H, et al. Application of large language models in automated construction of knowledge graphs for university subject domains[J]. Journal of Beijing University of Posts and Telecommunications (Social Sciences Edition), 2024, 26(1): 125-136.
- [68] 王磊, 时亚文, 刘晓丹, 等. 基于大模型知识追踪的多模态教育知识图谱构建与应用[J]. 电脑知识与技术, 2024, 20(20): 8-10.
WANG L, SHI Y W, LIU X D, et al. Construction and appli-

cation of multimodal educational knowledge map based on large model knowledge tracking[J]. Computer Knowledge and Technology, 2024, 20(20): 8-10.

[69] 陈欣, 元华芳, 周同, 等. 一种基于知识图谱的课程资源关联方法[J]. 北方工业大学学报, 2024, 36(2): 119-126.
CHEN X, QI H F, ZHOU T, et al. A course resource association method based on knowledge graph[J]. Journal of North China University of Technology, 2024, 36(2): 119-126.

[70] 罗江华, 张玉柳. 多模态大模型驱动的学科知识图谱进化及教育应用[J]. 现代教育技术, 2023, 33(12): 76-88.
LUO J H, ZHANG Y L. Evolution and educational application of discipline knowledge graph driven by multimodal large model[J]. Modern Educational Technology, 2023, 33(12): 76-88.

[71] 顾小清, 刘桐. 大模型时代的智适应学习研究: 进展、实例与展望[J]. 中国教育信息化, 2024, 30(5): 55-66.
GU X Q, LIU T. Research on adaptive learning in the era of large models: progress, examples, and prospects[J]. Chinese Journal of ICT in Education, 2024, 30(5): 55-66.

[72] 翟洁, 李艳豪, 孟天鑫, 等. 基于决策树和大模型的个性化计算机实验教学探索与实践[J]. 实验技术与管理, 2023, 40(12): 8-15.
ZHAI J, LI Y H, MENG T X, et al. Exploration and practice of personalized computer laboratory teaching based on decision trees and large models[J]. Experimental Technology and Management, 2023, 40(12): 8-15.

[73] JHAJJ G, ZHANG X K, GUSTAFSON J R, et al. Educational knowledge graph creation and Augmentation via LLMs [C]//Proceedings of the International Conference on Intelligent Tutoring Systems. Cham: Springer, 2024: 292-304.

[74] KABIR M R, LIN F. An LLM-powered adaptive practicing system[C]//Proceedings of the AIED 2023 Workshop on Empowering Education with LLMs—the Next-Gen Interface and Content Generation. Cham: Springer, 2023: 43-52.

[75] 廖云燕, 石荣旦, 黄箐, 等. 基于知识思维的大模型驱动教育智能化的分析与研究[C]//2024 计算思维与 STEM 教育研讨会暨 Bebras 中国社区年度工作会议论文集, 2024: 100-112.
LIAO Y Y, SHI R D, HUANG Q, et al. Analysis and research on education intelligence driven by large language model based on knowledge thinking[C]//Proceedings of the 2024 Symposium on Computational Thinking and STEM Education, and the Annual Meeting of the Bebras China Community, 2024: 100-112.

[76] YADAV G, TSENG Y J, NI X. Contextualizing problems to student interests at scale in intelligent tutoring system using large language models[C]//Proceedings of the AIED 2023 workshop on Empowering Education with LLMs—the Next-Gen Interface and Content Generation. Cham: Springer, 2023: 17-25.

[77] JIANG Z Y, ZHONG L, SUN M S, et al. Efficient knowledge infusion via KG-LLM alignment[C]//Findings of the Association for Computational Linguistics (ACL 2024). Stroudsburg: ACL, 2024: 2986-2999.

[78] 刘佳, 孙新, 张宇晴. 知识图谱与大语言模型协同的教育资源内容审查[J]. 华东师范大学学报(自然科学版), 2024(5): 57-69.
LIU J, SUN X, ZHANG Y Q. Educational resource content review method based on knowledge graph and large language model collaboration[J]. Journal of East China Normal University (Natural Science), 2024(5): 57-69.

[79] 余胜泉, 熊莎莎. 基于大模型增强的通用人工智能教师架构[J]. 开放教育研究, 2024, 30(1): 33-43.
YU S Q, XIONG S S. General artificial intelligence teacher architecture based on enhanced pre-trained large models[J]. Open Education Research, 2024, 30(1): 33-43.

[80] ZHANG T, KISHORE V, WU F, et al. BERTScore: evaluating text generation with BERT[C]//Proceedings of the 8th International Conference on Learning Representations (ICLR 2020). New York: Curran Associates, Inc, 2020: 5333-5375.

[81] ZHAO W, PEYRARD M, LIU F, et al. MoverScore: text generation evaluating with contextualized embeddings and earth mover distance[C]//Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing. Stroudsburg: ACL, 2019: 563-578.

[82] THOMPSON B, ALSHEHRI A. Improving arabic diacritization by learning to diacritize and translate[C]//Proceedings of the 19th International Conference on Spoken Language Translation (IWSLT 2022). Stroudsburg, PA: Association for Computational Linguistics, 2022: 11-21.

[83] IBRAHIM N, ABOULELA S, IBRAHIM A, et al. A survey on augmenting knowledge graphs (KGs) with large language models (LLMs): models, evaluation metrics, benchmarks, and challenges[J]. Discover Artificial Intelligence, 2024, 4(1): 76.

[84] PENG B, ZHU Y, LIU Y, et al. Graph retrieval-augmented generation: a survey [J]. arXiv:2408.08921, 2024.